Importación de librerías

```
In []: from selenium import webdriver # Webscrapping bot
from selenium.webdriver.common.by import By
from selenium.webdriver.common.keys import Keys
from selenium.common.exceptions import NoSuchElementException

from selenium.webdriver.firefox.options import Options as FirefoxOptions
from selenium.webdriver.chrome.options import Options as ChromiumOptions

from selenium.webdriver.common.by import By

In []: import logging # Para generar logs
from logging.handlers import TimedRotatingFileHandler
from logging import Formatter
import datetime
import os
import time

In []: import pandas as pd #Manejo de dataframes
```

Variables a modificar para adaptar el código

```
In [ ]: urlToScrap ="https://images.google.com/"
    deleteOldLogs = True

pathToDF = "../Outputs/"
    fileToDF = "ProdsToScrap.csv"

webdriverToUse = "chromium"
```

Pequeñas funciones de apoyo

```
In []: # Esta función se ha creado para mejorar comprensión de código en la configu

def UTCFormatter(logFormatter):
    Recibe un formatter de logeo
    Devuelve el horario a tiempo GMT
    logFormatter.converter = time.gmtime
    return logFormatter
```

Configuración de logs

```
In []: # Se inicia el proceso de registro de logs a nivel de INFO.
        logger = logging.getLogger('ScrapLog')
        logger.setLevel(logging.INF0)
        # Variables que determinan apartados posteriores
        timestamp = datetime.datetime.utcnow().strftime('%Y%m%d %H-%M-%S')
        filename=f'ScrapImages{timestamp}.log'
        formatter = logging.Formatter('[%(asctime)s] %(name)s {%(filename)s:%(linence)
In [ ]:
        Indican como se debe crear el archivo de log
        Si "deleteOldLogs" es True, sólo se conservará el último archivo de log
        if deleteOldLogs ==True:
            listFilesinCWD = os.listdir(os.getcwd())
            for element in listFilesinCWD:
                if element.endswith(".log"):
                    os.remove(os.path.join(os.getcwd(), element))
        fileHandler = logging.FileHandler(filename=filename)
        logging.Formatter.converter = time.gmtime
        fileHandler.setLevel(logging.INFO)
        fileHandler.setFormatter(UTCFormatter(formatter))
        logger.addHandler(fileHandler)
```

Importación de datos

Se importa el dataset especificado en las variables generales definidas anteriormente.

```
In [ ]: df = pd.read_csv(f"{pathToDF}{fileToDF}")
# df.drop(columns=df.columns[0], axis=1, inplace=True)
```

Comprobación de tamaño y composición del dataset importado como dataframe de Pandas.

Lógica del Scrapping

La siguiente función obtiene la url del primer resultado que aparece en google imágenes con el nombre del producto que recibe.

```
In [ ]:
       def ScrapFunction(prodToScrap, urlToScrap, driver):
            try:
                 logger.info(f"Started with: {prodToScrap}")
                 driver.implicitly wait(5)
                 driver.delete all cookies()
                 driver.implicitly wait(5)
                 driver.get(urlToScrap)
                 driver.implicitly wait(5)
                try:
                     acceptCookie = driver.find element(By.XPATH, "/html/body/div[2]/
                     acceptCookie.click()
                except:
                     pass
                 selectImageBox = driver.find element(By.XPATH, "/html/body/div[1]/di
                 selectImageBox.send keys(prodToScrap)
                 selectImageBox.send keys(Keys.ENTER)
                 driver.implicitly wait(5)
                 selectImage = driver.find element(By.XPATH, "/html/body/div[2]/c-wiz
                 selectImage.click()
                 driver.implicitly wait(5)
                 driver.refresh()
                 driver.implicitly wait(5)
                 urlImage = driver.find_element(By.XPATH, "/html/body/div[2]/c-wiz/di
                 logger.info(f"Scrapped: {urlImage}")
                 return urlImage
            except:
                 logger.info(f"FUNCTIONERROR: {prodToScrap}")
                 return None
```

Ejecución de Selenium. Tiene configurado tanto webdriver de *Chromium* como de *Firefox* por cuestiones de *debugging* (especialmente en términos de rendimiento). Finalmente se empleó geckodriver con *Firefox* (definido en variables generales anteriormente) en una instancia 'C2-standard-4' de *Google Cloud* con una duración total de 28 horas de cálculo.

El siguiente código traslada los nombres de los productos de uno en uno a la función anterior de Scrapeo y, con la url obtenida, lo graba en la columna generada "url" en el índice apropiado.

```
In [ ]: | print("Starting Webscrapping!")
        if webdriverToUse != "firefox":
            opts = ChromiumOptions()
            opts.add argument("--no-sandbox")
            opts.add argument("--incognito")
            opts.add argument("start-maximized")
            opts.add argument("window-size=1920,1080")
            opts.add_argument("--headless")
            opts.add experimental option("excludeSwitches", ["enable-automation"])
            opts.add experimental option('useAutomationExtension', False)
            driver = webdriver.Chrome(options=opts)
        else:
            opts = FirefoxOptions()
            opts.add argument("--no-sandbox")
            opts.add argument("--incognito")
            opts.add argument("start-maximized")
            opts.add argument("window-size=1920,1080")
            opts.add argument("--headless")
            driver = webdriver.Firefox(options=opts)
        driver.set page load timeout(30)
        driver.set window size(1920, 1080)
        for position, element in enumerate(df["name"].tolist()):
                 urlScrapped = ScrapFunction(element,urlToScrap,driver)
                 df.loc[df.index[position], 'url'] = urlScrapped
                 if position % 10:
                     df.to csv("Scrap.csv")
            except:
                 logger.info(f"Scrapped: {urlImage}")
                 if position % 10:
                     df.to csv("Scrap.csv")
                 continue
        driver.close()
```

In []: # Chequeo preliminar de resultados obtenidos df.head()

Out[]:		id	product_id	name	uri
	0	0	5645	Weleda Hombre Crema Hidratante	https://weledaint-prod.global.ssl.fastly.net/b
	1	1	28743	Gynea Gestagyn Men	https://www.gynea.com/wp-content/uploads /2018/
	2	2	68986	Endocare Tensage Ampollas	https://www.cantabrialabs.es/wp-content /upload
	3	3	9692	Lacer Colutorio Fluor+Xilitol Sabor Fresa	https://statics.promofarma.com/static/promofar
	4	4	81921	Age Protect Sérum Intensivo Multiacción Uriage	https://cdns3-2.primor.eu/62309-thickbox/age-p

Exportación de resultados a formato CSV

```
In [ ]: # Importante no eliminar "index=False" para manteener homogeneidad de los da
df.to_csv("ScrapDef.csv", index=False)
```